

COMP3242 小组项目方案（中文版本）

一、项目标题

SimCLR 关键组件对少标签视觉表征学习的影响：消融实验分析

（英文：Ablation Study of SimCLR Components for Label-Efficient Visual Representation Learning）

二、项目概述

本项目基于对比学习方法 SimCLR，研究其关键组件对视觉表示学习效果的影响。

我们不会从零设计新模型，而是：

- 实现一个简化版 SimCLR
- 对其关键组件进行消融实验（ablation study）
- 分析不同组件对模型表现的影响

此外，我们进一步扩展研究：

🔗 在不同标签数量（1%、10%、100%）下，分析这些组件的重要性

三、项目目标

本项目希望回答以下问题：

1. SimCLR 中哪些组件对表示学习最重要？
 2. 在少标签数据情况下，这些组件是否仍然有效？
 3. 对比学习相比监督学习，在低标签场景是否更有优势？
-

四、方法设计

4.1 Baseline: 简化版 SimCLR

我们实现一个基础 SimCLR 框架：

- 数据集：CIFAR-10
- 编码器：小型 CNN 或 ResNet-18
- Projection Head：两层 MLP

- 数据增强：
 - Random Crop
 - Color Jitter
 - Gaussian Blur
- 损失函数：NT-Xent

👉 该 baseline 用于后续对比分析

4.2 消融实验（核心部分）

我们对以下三个关键组件进行分析：

（1）数据增强（最重要）

三种设置：

- 弱增强：仅 random crop
- 中等增强：crop + color jitter
- 强增强：crop + color jitter + blur

👉 分析增强组合对表示学习的影响

（2）Projection Head

两种设置：

- 有 projection head（MLP）
- 无 projection head

👉 分析非线性映射的作用

（3）Batch Size

三种设置：

- 小 batch（128）
- 中 batch（256）

- 大 batch (512+)

🔗 分析负样本数量对对比学习的影响

五、评估方法

5.1 Linear Evaluation

- 冻结 encoder
- 训练线性分类器

评估指标:

🔗 分类准确率 (accuracy)

5.2 少标签评估 (项目亮点 🌟)

我们在不同标签比例下进行实验:

- 1% labels
- 10% labels
- 100% labels

对比:

- SimCLR 预训练 + 线性分类器
- 直接监督学习

🔗 分析表示在低标签场景下的效果

六、预期结果

我们预期:

- 强增强 → 表示质量提升明显
- Projection head → 显著提升性能
- 大 batch → 提高对比学习效果

此外:

🔗 对比学习在少标签情况下优于监督学习

七、（可选）GPU 分析（加分项👉）

为了进一步扩展项目，我们可以分析：

（1）Batch Size 与计算效率

- batch 越大 → accuracy 变化
- 同时 → GPU 利用率变化

（2）训练时间分析

对比：

- 不同 batch size
- 不同模型设置

👉 观察：

- 时间开销
- 计算成本

👉 注意：

GPU 部分只作为补充分析，不作为核心内容

八、项目贡献

本项目的贡献包括：

1. 系统分析 SimCLR 关键组件
2. 在少标签场景下研究其有效性
3. 提供对比学习在实际应用中的经验总结

九、时间安排

第 1 周：

- 完成 SimCLR baseline

第 2 周：

- 完成消融实验

第 3 周：

- 完成少标签评估

第 4 周：

- 整理结果 + 写报告
-

十、总结

本项目不是简单复现论文，而是：

🔗 基于 SimCLR 进行系统性分析与扩展

重点在于：

- 控制变量实验
- 结果分析
- 对关键设计的理解

而不是模型复杂度